



MEMORIA DE PRÁCTICAS: GENDER RECOGNITION

Visión por Computador

Enric Bonet Cortés
Máster en IARFID - Universidad Politécnica de Valencia

Gender Recognition

En esta ocasión, se parte de un Notebook en el que ya se realiza la carga directa desde Dropbox del dataset. El dataset, está compuesto de imágenes de tamaño 100x100 de personas en formato RGB, con un total de 10585 para el entrenamiento, y 2648 para el testeo del modelo que se implemente, que se utilizaran para resolver un problema de clasificación de dos clases, hombre o mujer.

Además, en esta ocasión, se exige implementar modelos de redes convolucionales que alcancen un 95% de acierto, y otro que permita alcanzar el 90% de acierto con un número de parámetros inferior o igual a 100.000.

Teniendo en cuenta estos dos objetivos, desde el primer momento este ejercicio se orientó a resolverse utilizando un único modelo que permitiese obtener mas de 95% de acierto con menos de 100.000 parámetros entrenables.

Tras realizar diferentes pruebas con diferentes topologías que se pueden encontrar en Internet sobre este problema de clasificación de género, el modelo resultante de red convolucional implementado tiene la siguiente configuración:

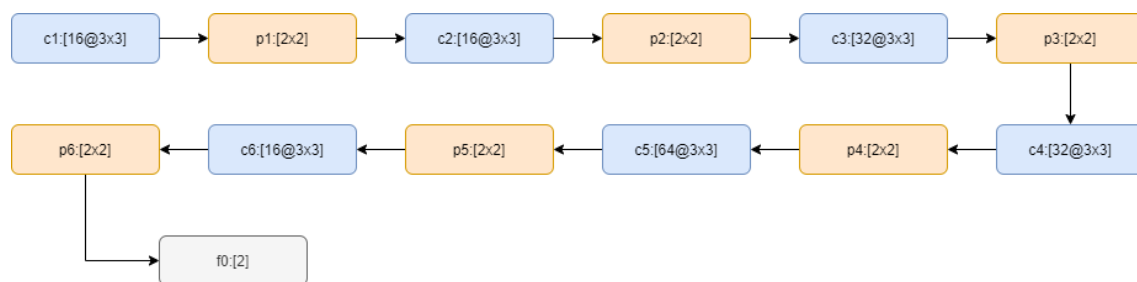


Figura 1 : Topología de la CNN para Gender Recognition

Esta configuración de topología, permite que la red convolucional reduzca al máximo la la imagen de entra mientras aprende a través de las convoluciones (a las que le hay que añadir Batch Normalization y Gaussian Noise con 0.1, que no se han podido mostrar en el diagrama), para que finalmente , la última capa de “Max-Pooling” extraiga una imagen de 1x1 con 64 filtros que se le pasa a una capa “Fully Connected” de solo dos neuronas, una para cada clase. A esto hay que añadirle también el uso del Data Augmentation mostrado en la **Figura 3**.

Al reducir al máximo el número de neuronas de las partes “Full Connected”, el número de parámetros del modelo total se reduce hasta uno **73.106 parámetros**, mientras que la precisión del modelo supera el 95% de acierto, como se muestra en la siguiente ilustración:

```
Epoch 72/75  
106/105 [=====] - 22s 208ms/step - loss: 0.0946 - accuracy: 0.9641 - val_loss: 0.0822 - val_accuracy: 0.9705  
Epoch 72/75  
106/105 [=====] - 22s 209ms/step - loss: 0.0900 - accuracy: 0.9654 - val_loss: 0.0821 - val_accuracy: 0.9694  
Epoch 73/75  
106/105 [=====] - 22s 210ms/step - loss: 0.0936 - accuracy: 0.9626 - val_loss: 0.0823 - val_accuracy: 0.9698  
Epoch 74/75  
106/105 [=====] - 22s 208ms/step - loss: 0.0916 - accuracy: 0.9640 - val_loss: 0.0826 - val_accuracy: 0.9698  
Epoch 75/75  
106/105 [=====] - 22s 208ms/step - loss: 0.0912 - accuracy: 0.9653 - val_loss: 0.0827 - val_accuracy: 0.9694  
  
Test  
  
[10] scores = model.evaluate(x_test, y_test, verbose=1)  
      print('Test loss:', scores[0])  
      print('Test accuracy:', scores[1])  
  
2648/2648 [=====] - 0s 179us/step  
Test loss: 0.0826667633137646  
Test accuracy: 0.9694108963012695
```

Figura 2: Resultado obtenido en Gender Recognition